



Федеральное государственное бюджетное образовательное учреждение  
высшего профессионального образования  
«Московский государственный технический университет имени Н.Э.  
Баумана»  
(МГТУ им. Н.Э. Баумана)

**Рубежный контроль 2**  
**по курсу «Технологии машинного обучения»**

Выполнил  
студент группы ИУ5-64  
XXX  
Вариант 7

Москва, 2021

## Задание

Для заданного набора данных (по Вашему варианту) постройте модели классификации или регрессии (в зависимости от конкретной задачи, рассматриваемой в наборе данных). Для построения моделей используйте методы 1 и 2 (по варианту для Вашей группы). Оцените качество моделей на основе подходящих метрик качества (не менее двух метрик). Какие метрики качества Вы использовали и почему? Какие выводы Вы можете сделать о качестве построенных моделей? Для построения моделей необходимо выполнить требуемую предобработку данных: заполнение пропусков, кодирование категориальных признаков, и т.д.

Группа	Метод №1	Метод №2
ИУ5-64Б	Линейная/логистическая регрессия	Градиентный бустинг

## Ход работы

```
In [1]: import pandas as pd

# Загрузка данных
data = pd.read_csv("../rk1/Admission_Predict_Ver1.1.csv")

data
```

```
Out[1]:
```

	Serial No.	GRE Score	TOEFL Score	University Rating	SOP	LOR	CGPA	Research	Chance of Admit
0	1	337	118	4	4.5	4.5	9.65	1	0.92
1	2	324	107	4	4.0	4.5	8.87	1	0.76
2	3	316	104	3	3.0	3.5	8.00	1	0.72
3	4	322	110	3	3.5	2.5	8.67	1	0.80
4	5	314	103	2	2.0	3.0	8.21	0	0.65
...	...	...	...	...	...	...	...	...	...
495	496	332	108	5	4.5	4.0	9.02	1	0.87
496	497	337	117	5	5.0	5.0	9.87	1	0.96
497	498	330	120	5	4.5	5.0	9.56	1	0.93
498	499	312	103	4	4.0	5.0	8.43	0	0.73
499	500	327	113	4	4.5	4.5	9.04	0	0.84

500 rows × 9 columns

```
In [2]: # Число пропусков
data.isnull().sum()
```

```
Out[2]: Serial No.      0
GRE Score      0
TOEFL Score    0
University Rating 0
SOP            0
LOR            0
CGPA           0
Research       0
Chance of Admit 0
dtype: int64
```

```
In [3]: # Целевой признак
target = "Chance of Admit"
```

```
In [4]: from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
    data.drop([target], axis=1),
    data[target],
    test_size=0.3,
    random_state=1,
)
```

## Выбор метрик

Mean absolute error - средняя абсолютная ошибка. Чем ближе значение к нулю, тем лучше качество регрессии. Основная проблема метрики состоит в том, что она не нормирована. Вычисляется с помощью функции `mean_absolute_error`.

Метрика  $R^2$  или коэффициент детерминации. Вычисляется с помощью функции `r2_score`.

## Линейная регрессия

```
In [5]: from sklearn.linear_model import LinearRegression

linreg = LinearRegression().fit(X_train, y_train)
```

```
In [6]:
```

```
from sklearn.metrics import r2_score, mean_absolute_error

linreg_predict = linreg.predict(X_test)
r2_score(y_test, linreg_predict), \
    mean_absolute_error(y_test, linreg_predict)
```

Out[6]: (0.8239704162441333, 0.04394760951798348)

## Градиентный бустинг

```
In [7]: from sklearn.ensemble import GradientBoostingRegressor

gboostreg = GradientBoostingRegressor(random_state=10).fit(X_train, y_train)
```

```
In [8]: gboostreg_predict = gboostreg.predict(X_test)
r2_score(y_test, gboostreg_predict), \
    mean_absolute_error(y_test, gboostreg_predict)
```

Out[8]: (0.8713378812774132, 0.0362669957034731)

## Вывод

$r^2$ \_score больше у GradientBoostingRegressor.

MAE ближе к нулю у GradientBoostingRegressor.

По обоим метрикам выигрывает градиентный бустинг

Loading [MathJax]/jax/output/CommonHTML/fonts/TeX/fontdata.js